

Análisis de tendencias climáticas globales: CO₂, temperatura, hielo y transición energética (2004–2024)

Integrantes:

- Nicolas Galvan Gonzalez
- Nicol Fernanda Garzon Torres
- Juan Diego Jauregui Rojas
- Joshua Alexander Rodriguez Amaya

Profesora: Camila Silva Gómez

Grupo: 3

Materia: DataXperience C304

Planteamiento del problema y objetivo del proyecto

El cambio climático se manifiesta a través de diferentes fenómenos relacionados entre sí, como el aumento de las emisiones de CO₂, el incremento de la temperatura, el derretimiento del hielo, el calentamiento de los océanos y los cambios en el uso de fuentes de energía. El conjunto de datos seleccionado permite analizar estos fenómenos y observar cómo han evolucionado durante el periodo 2004–2024.

El problema central del proyecto consiste en determinar qué relación tuvo el incremento de CO₂ y el aumento de la temperatura con el derretimiento del hielo entre 2004 y 2024. A partir de esta problemática también se busca comprender la relación entre el crecimiento de las energías renovables y la intensidad de las emisiones, identificar los países o regiones que presentan cambios climáticos más acelerados y analizar cómo varía la transición energética según el nivel de desarrollo socioeconómico.

Además, se busca estudiar la relación entre el aumento de la temperatura de los océanos y la anomalía de temperatura global, con el propósito de obtener una visión más completa de la evolución del cambio climático.

El **objetivo** del proyecto es analizar las tendencias climáticas globales entre 2004 y 2024 para identificar la relación entre el incremento de CO₂, el aumento de la temperatura, el derretimiento del hielo, el calentamiento de los océanos y la transición hacia energías renovables.

Búsqueda y obtención de los datos (fuente y justificación)

Para realizar el proyecto se seleccionó el conjunto de datos “Global Climate & CO₂ Anomalies (1990–2024)”, disponible públicamente en Kaggle y publicado por Mohan Krishna Thalla. El archivo utilizado es `global_climate_co2_anomalies.csv`.

Los datos provienen de fuentes climáticas, ambientales y socioeconómicas reconocidas, entre ellas NOAA, Banco Mundial, Our World in Data y Copernicus.

El conjunto original tiene una cobertura de 1990 a 2024 y contiene información de 30 países, con 12.600 registros mensuales y 54 variables. Incluye información relacionada con temperatura, CO₂, hielo marino, calor almacenado en los océanos y uso de energías renovables, entre otros indicadores.

Este conjunto de datos fue seleccionado porque reúne las principales variables necesarias para responder la pregunta de investigación del proyecto.

En particular, permite analizar la concentración y las emisiones de CO₂, las anomalías de temperatura, la extensión del hielo marino, el calor almacenado en los océanos, el uso y participación de energías renovables, la intensidad de las emisiones, la transición energética, las diferencias entre países y niveles de desarrollo socioeconómico.

La disponibilidad de estas variables permite estudiar no solamente la evolución de cada indicador de manera independiente, sino también las relaciones y patrones entre ellos, que es uno de los objetivos principales del proyecto.

Para el análisis específico del proyecto se toma como periodo de estudio 2004–2024, de acuerdo con el objetivo principal planteado.

Comprensión del conjunto de datos y descripción de las variables

El conjunto de datos “Global Climate & CO₂ Anomalies (1990–2024)” contiene información climática, ambiental, energética y socioeconómica. El dataset original comprende 30 países, 35 años de información, 12.600 registros mensuales y 54 variables.

Para el proyecto se trabajará específicamente con el periodo 2004–2024, ya que este corresponde al periodo definido en el objetivo principal de investigación.

Las variables se pueden organizar de acuerdo con las dimensiones principales del proyecto:

1. Variables de temperatura

Estas variables permiten analizar el comportamiento de la temperatura y sus anomalías:

- Anomalía de temperatura global: permite observar la variación de la temperatura global respecto a un valor de referencia.
- Anomalía de temperatura terrestre: permite analizar los cambios de temperatura sobre la superficie terrestre.
- Anomalía de temperatura oceánica: permite estudiar las variaciones de temperatura de los océanos.
- Anomalía de temperatura del Ártico: permite analizar el comportamiento de la temperatura en una de las zonas más relevantes para el estudio del hielo.

Estas variables son fundamentales para responder la pregunta relacionada con el aumento de temperatura y su posible relación con el derretimiento del hielo.

2. Variables relacionadas con CO₂ y emisiones

Dentro del conjunto se encuentran variables relacionadas con las emisiones de CO₂ y otros gases de efecto invernadero.

Entre ellas se consideran:

- CO₂: indicador utilizado para estudiar el comportamiento de las emisiones o concentración de dióxido de carbono. Emisiones de metano: permite complementar el análisis de gases de efecto invernadero.
- Óxido nitroso: indicador adicional de emisiones. Gases de efecto invernadero totales: permite observar el comportamiento general de las emisiones.
- CO₂ asociado al cambio de uso del suelo: permite considerar una fuente adicional de emisiones.

Estas variables permiten analizar la relación entre las emisiones y los cambios observados en las temperaturas.

3. Variables relacionadas con hielo

El conjunto incluye información sobre la extensión del hielo marino, una variable fundamental para responder directamente a la pregunta principal del proyecto.

Esta variable permite observar cómo ha evolucionado el hielo durante el periodo de estudio y compararla con el incremento de CO₂, las anomalías de temperatura y la temperatura del Ártico.

De esta manera se puede estudiar si existe una relación entre estas variables durante 2004–2024.

4. Variables relacionadas con los océanos

El dataset también incluye variables relacionadas con las condiciones térmicas de los océanos, entre ellas:

- Temperatura de la superficie del mar.
- Contenido de calor de los océanos.

Estas variables permiten analizar el calentamiento de los océanos y compararlo con la anomalía de temperatura global, respondiendo así una de las preguntas de apoyo del proyecto.

5. Variables energéticas

Para estudiar la transición energética se utilizan variables relacionadas con:

Consumo de energía primaria, participación de energías renovables y etapa de transición energética.

Estas variables permiten analizar si un mayor uso de energías renovables está relacionado con una menor intensidad de emisiones y comparar la situación entre países con diferentes niveles de desarrollo socioeconómico.

6. Variables socioeconómicas y de clasificación

El conjunto también contiene información que permite realizar comparaciones entre países y grupos:

- País.
- Continente o región.
- Grupo de ingresos o nivel de desarrollo socioeconómico.
- Etapa de transición energética.
- Nivel de intensidad de emisiones.
- Categorías relacionadas con el calentamiento.
- Puntaje de riesgo climático.

Estas variables son importantes porque permiten responder preguntas como qué países o regiones muestran cambios climáticos más acelerados y cómo varía la transición energética según el nivel de desarrollo socioeconómico.

Proceso completo de limpieza y preparación de los datos

Para desarrollar un análisis enfocado en el problema planteado inicialmente, se seleccionaron estratégicamente 21 variables del dataset original y se ajustó el período de estudio al rango 2004-2024. Al examinar en detalle las variables dentro de este rango, no se identificó ningún tipo de inconsistencia: los tipos de dato, las unidades de medida y los nombres de las columnas se encontraban correctamente definidos.

Con el fin de desarrollar el ejercicio de limpieza solicitado en clase, se introdujeron artificialmente errores controlados en el dataset, utilizando funciones de generación aleatoria (`numpy.random`). Tras esta modificación, se realizó un nuevo diagnóstico del dataset, se identificaron y solucionaron los siguientes problemas:

- **Duplicados:** Se eliminaron 22 filas duplicadas mediante `drop_duplicates()`.
- **Años fuera de rango:** Al revisar los valores máximo y mínimo de la columna `year`, se encontraron 38 registros con años imposibles, como 2099. Se eliminó cualquier fila cuyo año estuviera fuera del rango establecido (2004-2024).
- **Nombres de país inconsistentes:** Existían 102 formas distintas de escribir el nombre de un país, cuando en realidad solo hay 30 países en el dataset. Esta inconsistencia se debía a espacios al inicio o al final del texto y a diferencias de mayúsculas y minúsculas. Se corrigió eliminando los espacios sobrantes con `.str.strip()` y colocando solo la primera letra de cada palabra en mayúscula, mediante `.str.title()`.
- **Tipos de dato mezclados en `primary_energy_twh`:** Los valores de esta columna combinaban una parte numérica con la unidad de medida en texto (por ejemplo, "314.0 TWh"), lo que impedía realizar cálculos matemáticos. Se eliminó la parte de texto con `.str.replace(' TWh', '', regex=False)` y se convirtió la columna a tipo numérico, dado que la unidad de medida ya queda indicada en el nombre de la variable.
- **Negativos inválidos en `share_renewables_pct`:** Al tratarse de un valor porcentual respecto a la implementación de energías renovables, no tenía sentido que existieran valores negativos; se detectaron 76 casos. Se corrigieron aplicando valor absoluto con `.abs()`.
- **Negativos en `methane_emissions` y `nitrous_oxide`:** Estos valores negativos no se modificaron. Tras revisar la documentación del dataset, se determinó que estas cifras pueden representar procesos de captura o absorción neta, por lo que no representan un error.
- **Valores atípicos en `temp_anomaly_global`:** De acuerdo con la información proporcionada por el autor del dataset, esta variable debía tomar valores entre 0 y 3, pero se encontraron registros por fuera de ese rango. Estos valores se marcaron como faltantes (`NaN`) para tratarlos junto con el resto de los datos nulos.

- **Imputación de valores nulos:** se detectaron 507 valores faltantes entre las columnas `co2_emissions`, `share_renewables_pct`, `temp_anomaly_land` y `temp_anomaly_global`. Estos vacíos se completaron utilizando la mediana correspondiente a cada país y año, en lugar de un promedio general, dado que varias de estas variables presentan un comportamiento anual. Las columnas `sea_surface_temp_anom` y `ocean_heat_content` conservan valores nulos, pero estos corresponden a países sin costa.

Como resultado de estos siete pasos de limpieza, el dataset pasó de 7582 a 7522 filas, lo que representa una reducción inferior al 1%. Este bajo porcentaje de eliminación es un buen indicador de la calidad del proceso: se corrigieron los errores sin sacrificar información relevante.

```
import numpy as np
import pandas as pd
from google.colab import drive

drive.mount('/content/drive')
ruta = "/content/drive/MyDrive/Proyecto data/global_climate_co2_anomalies.csv"
df = pd.read_csv(ruta)

columnas_a_usar = ['country', 'continent', 'year', 'income_group', 'temp_anom',
                   'co2_emissions', 'methane_emissions', 'nitrous_oxide', 'total_ghg', 'land_use_change',
                   'primary_energy_twh', 'share_renewables_pct', 'climate_risk_score', 'warmed']

df_limpio = df[columnas_a_usar].copy()
df_limpio = df_limpio[(df_limpio['year'] >= 2004) & (df_limpio['year'] <= 2020)]

print(df_limpio.shape)
print("\n" + "=" * 60)
print(df_limpio.head(2))
print("\n" + "=" * 60)
print(df_limpio.info())
print("\n" + "=" * 60)

for columna in df_limpio.select_dtypes(include="object").columns:
    print(columna)
    print(df_limpio[columna].unique())
    print("\n" + "=" * 60)

for columna in df_limpio.select_dtypes(include=["int", "float"]).columns:
    print(columna)
    print(df_limpio[columna].describe())
    print("\n" + "=" * 60)

print(df_limpio.isna().sum())
print("\n" + "=" * 60)
print(f"    {df_limpio.duplicated().sum()} filas repetidas")
```

```
print("\n" + "=" * 60)
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount()
(7560, 21)
```

```
=====
      country      continent  year  income_group  temp_anomaly_global  \
168  Argentina  South America  2004  Upper Middle             0.60
169  Argentina  South America  2004  Upper Middle             0.54

      temp_anomaly_land  temp_anomaly_ocean  temp_anomaly_arctic  \
168                0.98                0.46                1.38
169                0.97                0.44                0.68

      co2_emissions  methane_emissions  ...  total_ghg  land_use_change_co2
168             205.8             39.1  ...    283.6             -1.5
169             205.8             39.1  ...    283.6             -1.5

      sea_surface_temp_anom  ocean_heat_content  primary_energy_twh  \
168                   NaN                13.49                273.1
169                   0.33                13.49                273.1

      share_renewables_pct  climate_risk_score  warming_category  \
168                   13.8                20.9             Elevated
169                   13.8                17.0             Elevated

      renewable_transition_stage  emission_intensity_level
168                      Medium                Medium
169                      Medium                Medium
```

```
[2 rows x 21 columns]
```

```
=====
<class 'pandas.core.frame.DataFrame'>
Index: 7560 entries, 168 to 12599
Data columns (total 21 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   country                               7560 non-null   object
1   continent                             7560 non-null   object
2   year                                  7560 non-null   int64
3   income_group                           7560 non-null   object
4   temp_anomaly_global                    7560 non-null   float64
5   temp_anomaly_land                      7560 non-null   float64
6   temp_anomaly_ocean                     7560 non-null   float64
7   temp_anomaly_arctic                    7560 non-null   float64
8   co2_emissions                          7560 non-null   float64
9   methane_emissions                     7560 non-null   float64
10  nitrous_oxide                          7560 non-null   float64
11  total_ghg                              7560 non-null   float64
12  land_use_change_co2                     7560 non-null   float64
13  sea_surface_temp_anom                   6971 non-null   float64
14  ocean_heat_content                       6968 non-null   float64
15  primary_energy_twh                       7560 non-null   float64
16  share_renewables_pct                     7560 non-null   float64
17  climate_risk_score                       7560 non-null   float64
18  warming_category                         7560 non-null   object
19  renewable_transition_stage               7560 non-null   object
20  emission_intensity_level                 7560 non-null   object
```

```

#ENSUCIAR
np.random.seed(42)
df_sucio = df_limpio.copy()
df_sucio = df_sucio.reset_index(drop=True)
n = len(df_sucio)

idx_todos = np.random.choice(df_sucio.index, size=int(n * 0.12), replace=False)

idx_duplicados      = idx_todos[0           : int(n*0.003)]
idx_nulos_co2       = idx_todos[int(n*0.003) : int(n*0.033)]
idx_nulos_renov     = idx_todos[int(n*0.033) : int(n*0.053)]
idx_texto           = idx_todos[int(n*0.053) : int(n*0.073)]
idx_outliers        = idx_todos[int(n*0.073) : int(n*0.083)]
idx_tipos_mezcl     = idx_todos[int(n*0.083) : int(n*0.098)]
idx_negativos       = idx_todos[int(n*0.098) : int(n*0.108)]
idx_año_raro        = idx_todos[int(n*0.108) : int(n*0.113)]
idx_nulos_temp      = idx_todos[int(n*0.113) : int(n*0.12)]

duplicados = df_sucio.loc[idx_duplicados].copy()
df_sucio = pd.concat([df_sucio, duplicados], ignore_index=True)

df_sucio.loc[idx_nulos_co2, 'co2_emissions'] = np.nan
df_sucio.loc[idx_nulos_renov, 'share_renewables_pct'] = np.nan
df_sucio.loc[idx_nulos_temp, 'temp_anomaly_land'] = np.nan

def ensuciar_texto(valor):
    opciones = [str(valor).upper(), str(valor).lower(), f" {valor} "]
    return np.random.choice(opciones)

df_sucio.loc[idx_texto, 'country'] = df_sucio.loc[idx_texto, 'country'].apply(ensuciar_texto)
df_sucio.loc[idx_outliers, 'temp_anomaly_global'] = np.random.uniform(50, 100)
df_sucio.loc[idx_tipos_mezcl, 'primary_energy_twh'] = df_sucio.loc[idx_tipos_mezcl, 'primary_energy_twh'].apply(ensuciar_texto)
df_sucio.loc[idx_negativos, 'share_renewables_pct'] = df_sucio.loc[idx_negativos, 'share_renewables_pct'].apply(ensuciar_texto)
df_sucio.loc[idx_año_raro, 'year'] = 2099

print("=" * 60)
print("1) DIMENSIONES")
print("=" * 60)
print(f"      {df_sucio.shape[0]} filas × {df_sucio.shape[1]} columnas")

print("\n" + "=" * 60)
print("2) TIPOS Y DATOS PRESENTES")
print("=" * 60)
df_sucio.info()

print("\n" + "=" * 60)
print("3) DATOS FALTANTES POR COLUMNA")
print("=" * 60)
print(df_sucio.isna().sum())

print("\n" + "=" * 60)
print("4) FILAS DUPLICADAS")
print("=" * 60)

```

```

print(f"    {df_sucio.duplicated().sum()} filas repetidas")

print("\n" + "=" * 60)
print("5) ESTADÍSTICOS DE LAS COLUMNAS NUMÉRICAS")
print("=" * 60)
print(df_sucio.describe())

print("\n" + "=" * 60)
print("6) VALORES ÚNICOS DE COLUMNAS DE TEXTO")
print("=" * 60)
for columna in ["country", "warming_category", "renewable_transition_stage"]
    print(f"\n--- {columna}: {df_sucio[columna].nunique()} valores distintos")
    print(df_sucio[columna].value_counts())

```

```

/tmp/ipykernel_1024/2579982323.py:32: FutureWarning: Setting an item of incompatible dtype is deprecated and will raise an error in a future version of pandas.
You may avoid this warning by setting a dtype explicitly when creating a DataFrame.
'312.0 TWh' '13044.0 TWh' '3364.6 TWh' '196.6 TWh' '201.6 TWh'
'3748.0 TWh' '7833.1 TWh' '334.7 TWh' '478.6 TWh' '619.4 TWh'
'1230.0 TWh' '443.7 TWh' '304.1 TWh' '7044.2 TWh' '1404.0 TWh'
'5582.0 TWh' '756.5 TWh' '6945.7 TWh' '5492.0 TWh' '1344.0 TWh'
'282.0 TWh' '4322.9 TWh' '4724.0 TWh' '1472.8 TWh' '212.4 TWh'
'2385.5 TWh' '216.3 TWh' '709.3 TWh' '322.9 TWh' '204.8 TWh' '210.9 TWh'
'922.0 TWh' '608.4 TWh' '198.4 TWh' '946.2 TWh' '2840.0 TWh' '1620.5 TWh'
'137.0 TWh' '509.3 TWh' '368.4 TWh' '372.1 TWh' '1404.1 TWh' '1439.5 TWh'
'1224.0 TWh' '4334.7 TWh' '568.9 TWh' '609.8 TWh' '1472.0 TWh'
'8059.0 TWh' '196.7 TWh' '204.9 TWh' '1443.8 TWh' '744.9 TWh' '518.8 TWh'
'5025.2 TWh' '2989.0 TWh' '292.1 TWh' '3512.7 TWh' '172.3 TWh'
'221.0 TWh' '338.9 TWh' '250.2 TWh' '412.5 TWh' '294.2 TWh' '13217.1 TWh'
'556.8 TWh' '424.6 TWh' '10552.0 TWh' '1204.3 TWh' '216.3 TWh'
'190.3 TWh' '14684.0 TWh' '409.2 TWh' '464.9 TWh' '4756.6 TWh'
'11896.0 TWh' '9892.2 TWh' '420.1 TWh' '3183.9 TWh' '1228.3 TWh'
'5293.4 TWh' '314.0 TWh' '1620.5 TWh' '899.2 TWh' '438.8 TWh'
'1948.0 TWh' '1361.1 TWh' '464.9 TWh' '1240.0 TWh' '1490.2 TWh'
'678.9 TWh' '157.4 TWh' '172.3 TWh' '172.5 TWh' '181.9 TWh' '2133.2 TWh'
'458.3 TWh' '1572.0 TWh' '3904.0 TWh' '250.2 TWh' '1572.0 TWh'
'721.9 TWh' '2600.8 TWh' '7044.2 TWh' '3904.0 TWh' '424.6 TWh'
'1248.8 TWh']' has dtype incompatible with float64, please explicitly cast
df_sucio.loc[idx_tipos_mezcl, 'primary_energy_twh'] = df_sucio.loc[idx_tipos_mezcl, 'primary_energy_twh'].astype(float64)

```

1) DIMENSIONES

```

=====
7582 filas x 21 columnas

```

2) TIPOS Y DATOS PRESENTES

```

<class 'pandas.core.frame.DataFrame'>

```

```

RangeIndex: 7582 entries, 0 to 7581

```

```

Data columns (total 21 columns):

```

#	Column	Non-Null Count	Dtype
0	country	7582 non-null	object
1	continent	7582 non-null	object
2	year	7582 non-null	int64
3	income_group	7582 non-null	object
4	temp_anomaly_global	7582 non-null	float64
5	temp_anomaly_land	7529 non-null	float64
6	temp_anomaly_ocean	7582 non-null	float64
7	temp_anomaly_arctic	7582 non-null	float64

8	co2_emissions	7355	non-null	float64
9	methane_emissions	7582	non-null	float64
10	nitrous_oxide	7582	non-null	float64
11	total_ghg	7582	non-null	float64
12	land_use_change_co2	7582	non-null	float64
13	sea_surface_temp_anom	6993	non-null	float64
14	ocean_heat_content	6989	non-null	float64
15	primary_energy_twh	7582	non-null	object
16	share_renewables_pct	7431	non-null	float64
17	climate_risk_score	7582	non-null	float64
18	warming_category	7582	non-null	object
19	renewable_transition_stage	7582	non-null	object
20	emission_intensity_level	7582	non-null	object

```
#LIMPIAR
df_final = df_sucio.copy()

# --- 1. Duplicados ---
print("\n" + "=" * 60)
print("PASO 1: Duplicados")
print("=" * 60)
print(f"    Duplicados antes: {df_final.duplicated().sum()}")
df_final = df_final.drop_duplicates()
print(f"    Duplicados después: {df_final.duplicated().sum()}")

# --- 2. Año fuera de rango ---
print("\n" + "=" * 60)
print("PASO 2: Año fuera de rango (2004-2024)")
print("=" * 60)
fuera_rango = (df_final['year'] < 2004) | (df_final['year'] > 2024)
print(f"    Filas con año inválido: {fuera_rango.sum()}")
df_final = df_final[~fuera_rango]

# --- 3. Texto inconsistente en 'country' ---
print("\n" + "=" * 60)
print("PASO 3: Texto inconsistente en 'country'")
print("=" * 60)
print(f"    Valores únicos antes: {df_sucio['country'].nunique()}")
df_final['country'] = df_final['country'].str.strip().str.title()
print(f"    Valores únicos después: {df_final['country'].nunique()}")

# --- 4. Tipos mezclados en 'primary_energy_twh' ---
print("\n" + "=" * 60)
print("PASO 4: Tipos mezclados en 'primary_energy_twh'")
print("=" * 60)
print(f"    Tipo antes: {df_sucio['primary_energy_twh'].dtype}")
df_final['primary_energy_twh'] = df_final['primary_energy_twh'].astype(str)
df_final['primary_energy_twh'] = pd.to_numeric(df_final['primary_energy_twh'], errors='coerce')
print(f"    Tipo después: {df_final['primary_energy_twh'].dtype}")

# --- 5. Negativos inválidos en 'share_renewables_pct' ---
print("\n" + "=" * 60)
print("PASO 5: Negativos inválidos en 'share_renewables_pct'")
print("=" * 60)
print(f"    Valores negativos antes: {(df_final['share_renewables_pct'] < 0).sum()}")
df_final['share_renewables_pct'] = df_final['share_renewables_pct'].clip(lower=0)
```

```

df_final['share_renewables_pct'] = df_final['share_renewables_pct'].abs()
print(f"    Valores negativos después: {(df_final['share_renewables_pct'] < 0

# --- 6. Outliers en 'temp_anomaly_global' ---
print("\n" + "=" * 60)
print("PASO 6: Valores atípicos en 'temp_anomaly_global'")
print("=" * 60)
print("--- ANTES ---")
print(df_final['temp_anomaly_global'].describe())

imposibles = df_final['temp_anomaly_global'] > 3
print(f"\n    Filas con valores imposibles: {imposibles.sum()}")
df_final.loc[imposibles, 'temp_anomaly_global'] = np.nan

print("\n--- DESPUÉS ---")
print(df_final['temp_anomaly_global'].describe())

# --- 7. Imputación de nulos (mediana por país y año) ---
print("\n" + "=" * 60)
print("PASO 7: Imputación de nulos (mediana por país y año)")
print("=" * 60)
columnas_a_imputar = ['co2_emissions', 'share_renewables_pct', 'temp_anomaly
for col in columnas_a_imputar:
    nulos_antes = df_final[col].isna().sum()
    df_final[col] = df_final.groupby(['country', 'year'])[col].transform(lam
    nulos_despues = df_final[col].isna().sum()
    print(f"    {col}: {nulos_antes} → {nulos_despues} nulos")

```

```

=====
PASO 1: Duplicados
=====
    Duplicados antes: 22
    Duplicados después: 0

=====
PASO 2: Año fuera de rango (2004-2024)
=====
    Filas con año inválido: 38

=====
PASO 3: Texto inconsistente en 'country'
=====
    Valores únicos antes: 102
    Valores únicos después: 30

=====
PASO 4: Tipos mezclados en 'primary_energy_twh'
=====
    Tipo antes: object
    Tipo después: float64

=====
PASO 5: Negativos inválidos en 'share_renewables_pct'
=====

```

Valores negativos antes: 76
Valores negativos después: 0

```
=====
PASO 6: Valores atípicos en 'temp_anomaly_global'
=====
```

```
--- ANTES ---
count      7522.000000
mean        1.601472
std         7.430875
min         0.310000
25%         0.660000
50%         0.810000
75%         1.010000
max         99.952475
Name: temp_anomaly_global, dtype: float64
```

Filas con valores imposibles: 76

```
--- DESPUÉS ---
count      7446.000000
mean        0.864663
std         0.295414
min         0.310000
25%         0.660000
50%         0.800000
75%         1.010000
max         1.710000
Name: temp_anomaly_global, dtype: float64
```

```
print("\n" + "=" * 62)
print("BITÁCORA DE LIMPIEZA · df_sucio → df_final")
print("=" * 62)
print(f"Filas iniciales           : {df_sucio.shape[0]}")
print(f"Filas finales             : {df_final.shape[0]}")
print(f"Filas descartadas          : {df_sucio.shape[0] - df_final.shape[0]}")
print(f"Países antes / después     : {df_sucio['country'].nunique()} → {df_final['country'].nunique()}")
print(f"Celdas vacías al terminar : {df_final.isna().sum().sum()} (nulos)")
print("-" * 62)
print("Decisiones tomadas:")
print("  1. Se eliminaron filas duplicadas exactas.")
print("  2. Se eliminaron filas con año fuera del rango 2004-2024.")
print("  3. Países unificados: ARGENTINA/argentina/' Argentina ' → Argentina")
print("  4. 'primary_energy_twh' con texto pegado ('314.0 TWh') convertido a número")
print("  5. Porcentajes negativos en share_renewables_pct corregidos con valores absolutos")
print("  6. Anomalías de temperatura >3°C marcadas como faltantes e imputadas")
print("  7. Nulos imputados con la mediana del mismo país y año (no genérica)")
print("  8. Negativos en methane_emissions/nitrous_oxide NO se corrigieron:")
print("     se investigó y pueden representar captura/absorción neta válida.")
print("  9. Nulos en sea_surface_temp_anom/ocean_heat_content NO se imputan:")
print("     son estructurales (países sin litoral), no error de captura.")
print("=" * 62)

print(df_sucio[df_sucio.duplicated(keep=False)].sort_values('country').head(5))
print(f"\nFilas con año imposible (fuera de 2004-2024): {(df_sucio['year'] < 2004 | df_sucio['year'] > 2024).count()}")
print(df_sucio[df_sucio['year'] > 2024][['country', 'year']].head(5))
```

```

for pais in sorted(df_sucio['country'].str.strip().str.title().unique()):
    variantes = sorted(str(v) for v in df_sucio[df_sucio['country'].str.strip() == pais].temp_anomaly_global)
    print(f"{pais} ← {variantes}")
print(df_sucio['share_renewables_pct'].describe())
print(df_sucio[['temp_anomaly_land', 'co2_emissions', 'share_renewables_pct']])
print("RANGO DE temp_anomaly_global ANTES DE LIMPIAR")
print(df_sucio['temp_anomaly_global'].describe()[['min', 'max']])

print("\nEJEMPLO: filas con valores imposibles (>3°C)")
print(df_sucio[df_sucio['temp_anomaly_global'] > 3][['country', 'year', 'temp_anomaly_global']])

print(f"\nTotal de filas afectadas: {(df_sucio['temp_anomaly_global'] > 3).count}")

```

```

=====
BITÁCORA DE LIMPIEZA · df_sucio → df_final
=====
Filas iniciales           : 7582
Filas finales             : 7522
Filas descartadas         : 60
Países antes / después    : 102 → 30
Celdas vacías al terminar : 1176 (nulos estructurales en sea_surface_temp)
=====

```

Decisiones tomadas:

1. Se eliminaron filas duplicadas exactas.
2. Se eliminaron filas con año fuera del rango 2004-2024.
3. Países unificados: ARGENTINA/argentina/' Argentina ' → Argentina.
4. 'primary_energy_twh' con texto pegado ('314.0 TWh') convertido a número.
5. Porcentajes negativos en share_renewables_pct corregidos con valor absoluto.
6. Anomalías de temperatura >3°C marcadas como faltantes e imputadas.
7. Nulos imputados con la mediana del mismo país y año (no genérica).
8. Negativos en methane_emissions/nitrous_oxide NO se corrigieron: se investigó y pueden representar captura/absorción neta válida.
9. Nulos en sea_surface_temp_anom/ocean_heat_content NO se imputan: son estructurales (países sin litoral), no error de captura.

```

=====
country      continent  year  income_group  temp_anomaly_global  \
23    Argentina  South America  2005  Upper Middle      0.72
7580   Argentina  South America  2005  Upper Middle      0.72
263    Australia  Oceania      2004  High Income       0.56
7562   Australia  Oceania      2004  High Income       0.56
694    Bangladesh  Asia      2019  Lower Middle      1.14
7563   Bangladesh  Asia      2019  Lower Middle      1.14

```

```

temp_anomaly_land  temp_anomaly_ocean  temp_anomaly_arctic  \
23                1.11                0.55                1.40
7580               1.11                0.55                1.40
263                0.96                0.42                0.93
7562               0.96                0.42                0.93
694                1.57                1.06                2.20
7563               1.57                1.06                2.20

```

```

co2_emissions  methane_emissions  ...  total_ghg  land_use_change_co2
23            223.4              38.1  ...    292.9           2.5
7580           223.4              38.1  ...    292.9           2.5
263            351.4              58.2  ...    460.5           0.5
7562           351.4              58.2  ...    460.5           0.5
694            316.5              56.0  ...    422.3          -0.0
7563           316.5              56.0  ...    422.3          -0.0

```

	sea_surface_temp_anom	ocean_heat_content	primary_energy_twh	\
23	0.49	14.59	321.2	
7580	0.49	14.59	321.2	
263	0.28	13.10	212.3	
7562	0.28	13.10	212.3	
694	0.81	33.01	249.9	
7563	0.81	33.01	249.9	

	share_renewables_pct	climate_risk_score	warming_category	\
23	14.3	23.7	Elevated	

Análisis exploratorio de datos (EDA)

Una vez finalizado el proceso de limpieza, se realizó un análisis exploratorio sobre el conjunto `df_limpio`, compuesto por 7.560 registros correspondientes a 30 países entre 2004 y 2024. El objetivo de esta etapa fue identificar visualmente el comportamiento de las variables relacionadas con la pregunta de investigación, antes de avanzar hacia el análisis estadístico y la construcción de los modelos predictivos.

El análisis se organizó en tres ejes: evolución temporal de las variables climáticas, relación entre variables numéricas y comparación entre continentes.

Evolución temporal de las variables clave

Para observar la evolución del cambio climático a lo largo del periodo de estudio, se calculó el promedio anual de cuatro variables: anomalía de temperatura global (°C), emisiones de CO₂ (millones de toneladas, Mt), contenido de calor oceánico (zettajulios, ZJ) y anomalía de temperatura del Ártico (°C). Esta última se utilizó como indicador aproximado del derretimiento de hielo, dado que el dataset no incluye una variable que mida directamente la extensión de hielo marino perdida (km²).

Se optó por agregar los datos a nivel anual, en lugar de dejarlos desagregados por país, porque el objetivo de esta gráfica es observar la tendencia global del periodo; mostrar los 30 países por separado habría dificultado la lectura del comportamiento general.

```
anual = df_limpio.groupby('year').agg(
    temp_anomaly_global=('temp_anomaly_global','mean'),
    co2_emissions=('co2_emissions','mean'),
    ocean_heat_content=('ocean_heat_content','mean'),
    temp_anomaly_arctic=('temp_anomaly_arctic','mean')
).reset_index()

fig, axes = plt.subplots(2, 2, figsize=(13,8))
fig.suptitle('Evolución global promedio (2004-2024)', fontsize=15, fontweight='bold')
axes[0,0].plot(anual['year'], anual['temp_anomaly_global'], color=c_temp, marker=)
```

```

axes[0,0].set_title('Anomalía de temperatura global (°C)')
axes[0,1].plot(anual['year'], anual['co2_emissions'], color=c_co2, marker='o', )
axes[0,1].set_title('Emisiones de CO2 (Mt, promedio)')
axes[1,0].plot(anual['year'], anual['ocean_heat_content'], color=c_ocean, marker='o')
axes[1,0].set_title('Contenido de calor oceánico (ZJ)')
axes[1,1].plot(anual['year'], anual['temp_anomaly_arctic'], color=c_ice, marker='o')
axes[1,1].set_title('Anomalía de temperatura ártica (°C)')
plt.tight_layout()
plt.savefig('1_tendencias_globales.png', dpi=150, bbox_inches='tight')
plt.show()

```

Figura 1. Evolución global promedio (2004-2024). La anomalía de temperatura global pasó de 0,6 °C a 1,6 °C; el CO₂ promedio de 890 Mt a 1.200 Mt; el calor oceánico de 13 ZJ a 40 ZJ; y la anomalía ártica de 1,2 °C a 3,4 °C.

Relación entre variables numéricas

Para explorar si existe relación entre las variables climáticas y las emisiones, se construyó una matriz de correlación de Pearson sobre ocho variables clave:

temp_anomaly_global (°C), temp_anomaly_arctic (°C), co2_emissions (Mt), total_ghg (Mt CO₂-eq), sea_surface_temp_anom (°C), ocean_heat_content (ZJ), share_renewables_pct (%) y climate_risk_score (índice, escala 0-100 sin unidad física).

```

vars_clave = ['temp_anomaly_global', 'temp_anomaly_arctic', 'co2_emissions', 'total_ghg',
              'sea_surface_temp_anom', 'ocean_heat_content', 'share_renewables_pct', 'climate_risk_score']
corr = df_limpio[vars_clave].corr()

plt.figure(figsize=(9,7))
sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdBu_r', center=0, vmin=-1, vmax=1, square=True, linewidths=0.5, cbar_kws={'label': 'Correlación'})
plt.title('Matriz de correlación: CO2, temperatura y océano', fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig('2_matriz_correlacion.png', dpi=150, bbox_inches='tight')
plt.show()

```

Figura 2. Matriz de correlación de Pearson entre variables climáticas y de emisiones.

Como complemento, se generaron dos gráficas de dispersión, sin agregar los datos por año, para observar la forma de la relación entre pares de variables medidas en °C y ZJ:

```

fig, axes = plt.subplots(1, 2, figsize=(13,5.5))
axes[0].scatter(df_limpio['sea_surface_temp_anom'], df_limpio['temp_anomaly_global'])

```

```

axes[0].set_xlabel('Anomalía temp. superficie del mar (°C)')
axes[0].set_ylabel('Anomalía temp. global (°C)')
axes[0].set_title('Temp. global vs. temp. superficie del mar')
axes[1].scatter(df_limpio['ocean_heat_content'], df_limpio['temp_anomaly_arctic'])
axes[1].set_xlabel('Contenido de calor oceánico (ZJ)')
axes[1].set_ylabel('Anomalía temp. ártica (°C)')
axes[1].set_title('Calor oceánico vs. temp. ártica')
plt.tight_layout()
plt.savefig('3_dispersion_oceano.png', dpi=150, bbox_inches='tight')
plt.show()

```

Figura 3. Dispersión entre variables oceánicas y de temperatura (°C, ZJ).

Comparación por continente

Por último, se comparó el comportamiento de las variables climáticas entre continentes: el `climate_risk_score` (índice 0-100) mediante un diagrama de cajas, y la anomalía de temperatura global (°C) mediante una gráfica de líneas desagregada por continente.

```

fig, axes = plt.subplots(1, 2, figsize=(13,5.5))
df_limpio.boxplot(column='climate_risk_score', by='continent', ax=axes[0])
axes[0].set_title('Riesgo climático por continente (índice 0-100)')
plt.suptitle('')
anual_cont = df_limpio.groupby(['year', 'continent'])['temp_anomaly_global'].mean()
for cont in df_limpio['continent'].unique():
    sub = anual_cont[anual_cont['continent']==cont]
    axes[1].plot(sub['year'], sub['temp_anomaly_global'], marker='o', markersize=8)
axes[1].set_title('Anomalía de temperatura por continente (°C)')
axes[1].legend(fontsize=8)
plt.tight_layout()
plt.savefig('4_comparacion_continentes.png', dpi=150, bbox_inches='tight')
plt.show()

```

Figura 4. Comparación del riesgo climático (índice 0-100) y la anomalía de temperatura (°C) por continente.

✓ Análisis estadístico realizado

El análisis estadístico se apoyó en dos técnicas principales: estadística descriptiva y análisis de correlación.

En primer lugar, se calcularon los estadísticos descriptivos (media, desviación estándar, mínimo, máximo y cuartiles) de todas las variables numéricas del conjunto

`df_limpio`, mediante la función `describe()` de pandas:

```
for columna in df_limpio.select_dtypes(include=["int", "float"]).columns:  
    print(columna)  
    print(df_limpio[columna].describe())
```

Esto permitió confirmar que las variables se encontraban dentro de los rangos esperados. La anomalía de temperatura global se ubicó entre 0,31 °C y 1,71 °C, consistente con el rango documentado por el autor del dataset (0-3 °C), mientras que la anomalía ártica alcanzó valores de hasta 4,03 °C, reflejando un calentamiento proporcionalmente mayor en esa región frente al promedio global. Las emisiones de CO₂ oscilaron entre 20,1 Mt y 11.348,6 Mt, y el contenido de calor oceánico entre 12,79 ZJ y 40,4 ZJ.

En segundo lugar, se calculó la matriz de correlación de Pearson descrita en la sección anterior:

```
corr = df_limpio[vars_clave].corr()
```

Este análisis arrojó un hallazgo relevante: mientras que la anomalía de temperatura global (°C) presenta una correlación muy alta con la temperatura de la superficie del mar (0,98) y con la anomalía ártica (0,96), su correlación con las emisiones de CO₂ en Mt es prácticamente nula (0,04) al calcularse fila por fila, es decir, a nivel país-año.


Esto se explica por la naturaleza de los datos: la anomalía de temperatura global es un valor mundial, idéntico en °C para todos los países en un mismo año, mientras que las emisiones de CO₂ varían sustancialmente en Mt entre países según el tamaño de su economía y su población. Al calcular la correlación a nivel de fila, se está comparando una variable que no cambia entre países contra una que sí varía ampliamente, lo que diluye el coeficiente resultante. La relación entre CO₂ y temperatura sí resulta evidente cuando se observan las series agregadas por año, como se mostró en la Figura 1.

Este resultado se tuvo en cuenta como criterio metodológico al momento de interpretar el resto de las correlaciones del proyecto: una variable con comportamiento global-uniforme, como las anomalías de temperatura (°C), exhibirá correlaciones más bajas frente a variables que varían por país, como el CO₂ (Mt) o el calor oceánico (ZJ), no porque la relación entre ambas no exista, sino por el nivel de agregación en el que se realiza la comparación.

```
import matplotlib.pyplot as plt  
import seaborn as sns  
  
c_temp, c_co2, c_ocean, c_ice = '#e74c3c', '#8e44ad', '#2980b9', '#1abc9c'
```

```
# Visualización de tendencias globales anuales
anual = df_limpio.groupby('year').agg(
    temp_anomaly_global=('temp_anomaly_global','mean'),
    co2_emissions=('co2_emissions','mean'),
    ocean_heat_content=('ocean_heat_content','mean'),
    temp_anomaly_arctic=('temp_anomaly_arctic','mean')
).reset_index()

fig, axes = plt.subplots(2, 2, figsize=(13,8))
fig.suptitle('Evolución global promedio (2004-2024)', fontsize=15, fontweight='bold')
axes[0,0].plot(anual['year'], anual['temp_anomaly_global'], color=c_temp, marker='o')
axes[0,0].set_title('Anomalía de temperatura global (°C)')
axes[0,0].grid(alpha=0.3)
axes[0,1].plot(anual['year'], anual['co2_emissions'], color=c_co2, marker='o')
axes[0,1].set_title('Emisiones de CO2 (promedio)')
axes[0,1].grid(alpha=0.3)
axes[1,0].plot(anual['year'], anual['ocean_heat_content'], color=c_ocean, marker='o')
axes[1,0].set_title('Contenido de calor oceánico')
axes[1,0].grid(alpha=0.3)
axes[1,1].plot(anual['year'], anual['temp_anomaly_arctic'], color=c_ice, marker='o')
axes[1,1].set_title('Anomalía de temperatura ártica (°C)\n(proxy de derretimiento)')
axes[1,1].grid(alpha=0.3)
plt.tight_layout()
plt.savefig('1_tendencias_globales.png', dpi=150, bbox_inches='tight')
plt.show()
```


Evolución global promedio (2004-2024)

```
# CELDA 3: matriz de correlación y dispersión océano-clima
vars_clave = ['temp_anomaly_global', 'temp_anomaly_arctic', 'co2_emissions', 't
              'sea_surface_temp_anom', 'ocean_heat_content', 'share_renewables']
corr = df_limpio[vars_clave].corr()


plt.figure(figsize=(9,7))
sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdBu_r', center=0, vmin=-1, v
            square=True, linewidths=0.5, cbar_kws={'label': 'Correlación'})
plt.title('Matriz de correlación: CO2, temperatura y océano', fontsize=13, f
plt.tight_layout()
plt.savefig('2_matriz_correlacion.png', dpi=150, bbox_inches='tight')
```

```
plt.show()

fig, axes = plt.subplots(1, 2, figsize=(13,5.5))
axes[0].scatter(df_limpio['sea_surface_temp_anom'], df_limpio['temp_anomaly_
axes[0].set_xlabel('Anomalía temp. superficie del mar')
axes[0].set_ylabel('Anomalía temp. global')
axes[0].set_title('Temp. global vs. temp. superficie del mar')
axes[0].grid(alpha=0.3)
axes[1].scatter(df_limpio['ocean_heat_content'], df_limpio['temp_anomaly_arc
axes[1].set_xlabel('Contenido de calor oceánico')
axes[1].set_ylabel('Anomalía temp. ártica')
axes[1].set_title('Calor oceánico vs. temp. ártica (proxy hielo)')
axes[1].grid(alpha=0.3)
plt.tight_layout()
plt.savefig('3_dispersion_oceano.png', dpi=150, bbox_inches='tight')
plt.show()
```



```
# CELDA 4: comparación por continente
fig, axes = plt.subplots(1, 2, figsize=(13,5.5))
df_limpio.boxplot(column='climate_risk_score', by='continent', ax=axes[0])
axes[0].set_title('Riesgo climático por continente')
axes[0].set_xlabel('')
plt.suptitle('')
anual_cont = df_limpio.groupby(['year', 'continent'])['temp_anomaly_global'].
for cont in df_limpio['continent'].unique():
    sub = anual_cont[anual_cont['continent']==cont]
    axes[1].plot(sub['year'], sub['temp_anomaly_global'], marker='o', marker
axes[1].set_title('Anomalía de temperatura por continente')
axes[1].legend(fontsize=8)
axes[1].grid(alpha=0.3)
plt.tight_layout()
plt.savefig('4_comparacion_continentes.png', dpi=150, bbox_inches='tight')
plt.show()
```



Hallazgo de patrones, relaciones e insights

Del análisis exploratorio se identificaron varios patrones relevantes para responder la pregunta de investigación.

Aceleración reciente del calentamiento global

Las cuatro variables analizadas (temperatura global, CO₂, calor oceánico y temperatura ártica) muestran una tendencia creciente sostenida durante todo el periodo 2004-2024. Sin embargo, el crecimiento no es constante: entre 2022 y 2024 se observa un salto mucho más pronunciado que en años anteriores, especialmente en la temperatura global (de 0.8°C a 1.6°C) y en la temperatura ártica (de 1.7°C a 3.9°C). Esto sugiere que el calentamiento no solo continúa, sino que se está acelerando en los años más recientes del periodo estudiado.

Fuerte relación entre temperatura, océano y hielo

La matriz de correlación confirma el mecanismo físico detrás del problema planteado: la anomalía de temperatura global correlaciona casi perfectamente con la anomalía de temperatura ártica (0.96) y con la anomalía de temperatura de la superficie del mar (0.98), y de forma fuerte con el calor oceánico (0.77) y con el riesgo climático (0.80). Esto respalda la hipótesis inicial del proyecto: el aumento de temperatura global está estrechamente ligado al calentamiento de los océanos y, a través de este, al derretimiento del hielo (aproximado con la anomalía ártica).

Relación débil entre CO₂/GEI y las variables de temperatura

Un hallazgo inesperado es que las emisiones de CO₂ y los gases de efecto invernadero totales prácticamente no correlacionan con la temperatura (0.03-0.04) ni con el riesgo climático (0.03) dentro del conjunto de datos. Esto no significa que el CO₂ no cause calentamiento, sino que su efecto opera de forma acumulada a nivel global a lo largo de décadas, mientras que el dataset compara países y años puntuales: un país con emisiones altas en un año determinado no necesariamente presenta mayor temperatura ese mismo año, porque el calentamiento responde a la acumulación histórica de gases y no a la emisión anual de un país específico. Este hallazgo es clave porque anticipa por qué el modelo de regresión (que usa CO₂ y energía para predecir riesgo climático) tiene un desempeño bajo, tal como se explica en la siguiente sección.

Diferencias entre continentes: calentamiento sincronizado, pero riesgo desigual

Al comparar la anomalía de temperatura por continente, las seis líneas (África, Asia, Europa, América del Norte, América del Sur y Oceanía) prácticamente se superponen a lo largo de todo el periodo. Esto indica que el aumento de temperatura es un fenómeno global y sincronizado, no algo que ocurra de forma diferenciada por región. Sin embargo, al observar el riesgo climático por continente, sí aparecen diferencias claras: África y Asia presentan medianas más altas y más países-año en niveles de riesgo elevado, mientras que Europa y Oceanía muestran valores más bajos. Esto sugiere que, aunque todos los continentes se calientan al mismo ritmo, el riesgo climático depende también de factores adicionales de vulnerabilidad y exposición, no únicamente de la temperatura.

Renovables y riesgo climático

La participación de energías renovables (`share_renewables_pct`) muestra una correlación positiva débil con el riesgo climático (0.19-0.23), un resultado contraintuitivo. Una posible explicación es que los países que más han avanzado en su transición energética suelen ser economías desarrolladas con un historial largo de emisiones acumuladas, por lo que ya arrastran un riesgo climático alto pese a estar reduciendo sus emisiones actuales.

Selección del modelo y justificación de su elección

Para responder con el análisis de los datos, se desarrollaron dos modelos de predicción: una regresión lineal múltiple y un Random Forest.

Ambos modelos se seleccionaron porque funcionan adecuadamente con las variables numéricas y categóricas presentes en el dataset, sin necesidad de transformaciones complejas. Además, se complementan entre sí: la regresión lineal múltiple ofrece una predicción numérica y el Random Forest permite obtener una predicción categórica.

Respecto a los demás modelos vistos, la regresión binomial y la regresión logística se descartaron dado que ambos requieren una variable de tipo binario, y ninguna de las variables presentan solo dos categorías. Se descartó K-Means, ya que esta técnica busca agrupar datos sin categorías previas, pero el dataset ya cuenta con variables categóricas debidamente definidas.

Para evaluar ambos modelos, el dataset se dividió en dos partes, el 80% lo utiliza como entrenamiento y el 20% para realizar pruebas, agrupando las observaciones por país para evitar que datos del mismo país aparecieran simultáneamente en ambos conjuntos.

1. Regresión lineal múltiple

Busca estudiar si las variables de emisiones y consumo energético permiten predecir el riesgo climático de un país. Para lograrlo se le suministraron 5 variables predictoras: `co2_emissions`, `total_gh`, `primary_energy_twh`, `land_use_change_co2`, `share_renewables_pct`. Con el objetivo de predecir un número de 0-100 que represente el riesgo climático de un país.

El desempeño del modelo se evaluó mediante el coeficiente de determinación (R^2) y el error absoluto medio (MAE).

2. Random Forest

Se entrenó un modelo compuesto de 100 árboles de decisión para determinar si a partir del continente y sus cambios de temperatura se puede predecir la categoría de

calentamiento de un país. Como variables predictoras se usaron: `continent`, `temp_anomaly_land`, `temp_anomaly_ocean`, `temp_anomaly_arctic` y `climate_risk_score`. El resultado es una variable categórica, con cuatro niveles posibles: Normal, Elevado, Alto y Extremo.

El desempeño se evaluó mediante la exactitud global (accuracy) y un reporte de clasificación detallado por categoría (precisión, sensibilidad y F1-score).

✓ Aplicación del modelo

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import GroupShuffleSplit
from sklearn.metrics import r2_score, mean_absolute_error
import pandas as pd

# 1. Variables predictoras (solo emisiones y energía) y objetivo
X = df_final[['co2_emissions', 'total_ghg', 'primary_energy_twh',
              'land_use_change_co2', 'share_renewables_pct']]
y = df_final['climate_risk_score']

# 2. Dividir por país completo (para no repetir el error de fuga de datos)
splitter = GroupShuffleSplit(test_size=0.2, random_state=42)
train_idx, test_idx = next(splitter.split(X, y, groups=df_final['country']))
X_train, X_test = X.iloc[train_idx], X.iloc[test_idx]
y_train, y_test = y.iloc[train_idx], y.iloc[test_idx]

# 3. Crear y entrenar el modelo
modelo_multiple = LinearRegression()
modelo_multiple.fit(X_train, y_train)

# 4. Predecir sobre datos que el modelo nunca vio
y_pred = modelo_multiple.predict(X_test)

# 5. Evaluar qué tan bueno es
r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
print(f"R²: {r2:.4f}")
print(f"MAE: {mae:.2f}")

# 6. Ver el peso de cada variable
coeficientes = pd.DataFrame({
    'variable': X.columns,
    'coeficiente': modelo_multiple.coef_
}).sort_values('coeficiente', key=abs, ascending=False)
print("\nCoeficientes:")
print(coeficientes)
```

R²: 0.0408

MAE: 7.47



Coeficientes:

	variable	coeficiente
4	share_renewables_pct	0.090399
3	land_use_change_co2	0.073107
1	total_ghg	0.000629
0	co2_emissions	-0.000568
2	primary_energy_twh	0.000038

```
import matplotlib.pyplot as plt
```

```
plt.figure(figsize=(7,6))
plt.scatter(y_test, y_pred, alpha=0.4, color='steelblue')
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--',
plt.xlabel('Riesgo climático real')
plt.ylabel('Riesgo climático predicho')
plt.title('Regresión Múltiple: Predicho vs. Real')
plt.legend()
plt.tight_layout()
plt.savefig('regresion_pred_vs_real.png', dpi=150)
plt.show()
```

```
plt.figure(figsize=(7,5))
coef_ordenados = coeficientes.sort_values('coeficiente')
colores = ['lightsteelblue' if x < 0 else 'steelblue' for x in coef_ordenado]
plt.barh(coef_ordenados['variable'], coef_ordenados['coeficiente'], color=colores)
plt.xlabel('Coeficiente')
plt.title('Peso de cada variable en el riesgo climático')
plt.tight_layout()
plt.savefig('regresion_coeficientes.png', dpi=150)
plt.show()
```



```

from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GroupShuffleSplit
from sklearn.metrics import accuracy_score, classification_report
from sklearn.preprocessing import LabelEncoder

# 1. Convertir 'continent' (texto) a número
le = LabelEncoder()
df_final['continent_num'] = le.fit_transform(df_final['continent'])

# 2. Variables predictoras y objetivo
X = df_final[['continent_num', 'temp_anomaly_land', 'temp_anomaly_ocean',
              'temp_anomaly_arctic', 'climate_risk_score']]
y = df_final['warming_category']

# 3. Dividir por país completo
splitter = GroupShuffleSplit(test_size=0.2, random_state=42)
train_idx, test_idx = next(splitter.split(X, y, groups=df_final['country']))
X_train, X_test = X.iloc[train_idx], X.iloc[test_idx]
y_train, y_test = y.iloc[train_idx], y.iloc[test_idx]

# 4. Crear y entrenar el modelo (100 árboles)
modelo_rf = RandomForestClassifier(n_estimators=100, random_state=42)
modelo_rf.fit(X_train, y_train)

# 5. Predecir y evaluar
y_pred = modelo_rf.predict(X_test)
exactitud = accuracy_score(y_test, y_pred)
print(f"Exactitud: {exactitud:.2%}")
print("\nReporte por categoría:")
print(classification_report(y_test, y_pred))

# 6. Importancia de cada variable
importancias = pd.DataFrame({
    'variable': X.columns,
    'importancia': modelo_rf.feature_importances_
}).sort_values('importancia', ascending=False)
print("\nImportancia de cada variable:")
print(importancias)

```

Exactitud: 94.16%

Reporte por categoría:

	precision	recall	f1-score	support
Elevated	0.96	0.96	0.96	867
Extreme	0.96	0.93	0.95	168
High	0.91	0.91	0.91	383
Normal	0.88	0.88	0.88	89
accuracy			0.94	1507
macro avg	0.93	0.92	0.92	1507
weighted avg	0.94	0.94	0.94	1507

Importancia de cada variable:


variable	importancia
----------	-------------

2	temp_anomaly_ocean	0.422072
1	temp_anomaly_land	0.333893
3	temp_anomaly_arctic	0.163846
4	climate_risk_score	0.066220
0	continent_num	0.013967


```
plt.figure(figsize=(7,5))
imp_ordenadas = importancias.sort_values('importancia')
plt.barh(imp_ordenadas['variable'], imp_ordenadas['importancia'], color='steelblue')
plt.xlabel('Importancia')
plt.title('Importancia de variables – Categoría de calentamiento')
plt.tight_layout()
plt.savefig('rf_importancias.png', dpi=150)
plt.show()
```

```
from sklearn.metrics import ConfusionMatrixDisplay
```

```
plt.figure(figsize=(6,6))
ConfusionMatrixDisplay.from_predictions(y_test, y_pred, cmap='Blues', xticks=10, yticks=10)
plt.title('Matriz de confusión – Categoría de calentamiento')
plt.tight_layout()
plt.savefig('rf_matriz_confusion.png', dpi=150)
plt.show()
```



<Figure size 600x600 with 0 Axes>



Evaluación del modelo e interpretación de los resultados

1. Regresión lineal múltiple

Los coeficientes muestran qué variables afectan más el riesgo climático de cada país,